

基于深度学习的辐射图像超分辨率重建方法

孙跃文^{1,2} 李立涛^{1,2} 丛 鹏^{1,2} 向新程^{1,2,*} 郭肖静^{1,2}

(1. 清华大学 核能与新能源技术研究院, 北京 100084; 2. 核检测技术北京市重点实验室, 北京 100084)

摘要: 安全检查系统中, 数字化 X 射线摄影技术获得的辐射图像空间分辨率较低, 影响图像的视觉效果。为了对单幅低分辨率辐射图像的空间分辨率进行提升, 提出一种基于深度学习的超分辨率重建方法。该方法利用引入残差网络结构的卷积神经网络模型, 对训练集中的辐射图像样本进行了训练, 拟合出低分辨率图像和高分辨率图像的映射关系。实验结果表明, 与传统的超分辨率重建方法相比, 本方法在量化指标和视觉效果上均有较大的改善, 且具备较快的处理速度。研究结果表明, 深度学习方法在辐射图像处理中有较大的潜力。

关键词: 辐射图像; 超分辨率重建; 深度学习

中图分类号: TL8; TP391.4

文献标志码: A

文章编号: 1000-6931(2017)05-0890-06

doi: 10.7538/yzk.2017.51.05.0890

Super-resolution Method for Radiation Image Based on Deep Learning

SUN Yue-wen^{1,2}, LI Li-tao^{1,2}, CONG Peng^{1,2}, XIANG Xin-cheng^{1,2,*}, GUO Xiao-jing^{1,2}

(1. Institute of Nuclear and New Energy Technology, Tsinghua University, Beijing 100084, China;

2. Beijing Key Laboratory of Nuclear Detection & Measurement Technology, Beijing 100084, China)

Abstract: In the security check system, the spatial resolution of radiation image generated by digital radiography is often so low that reduces the image quality. In this work, a super-resolution method based on deep learning was proposed. Using the convolution neural network with residual block, the method trained the radiation image sample in dataset and found the mapping function of low-resolution image to high-resolution image. The experiment result shows that the super-resolution method can deliver superior performance compared with other traditional methods while maintaining an excellent speed. The study result indicates the great potential of deep learning in radiation image processing.

Key words: radiation image; super-resolution; deep learning

数字化 X 射线摄影技术作为一种典型的非接触检测方法, 在医疗检测和安全检查领域中应用广泛。由于成像速度快, 产生的数字辐

射图像便于存储、拷贝和后处理, 数字化 X 射线摄影技术已成为安全检查领域的主要应用技术。然而受探测器物理尺寸和数目的限制, 数

收稿日期: 2016-11-29; 修回日期: 2017-02-16

作者简介: 孙跃文(1993—), 男, 陕西西安人, 硕士研究生, 核科学与技术专业

* 通信作者: 向新程, E-mail: inetxxc@tsinghua.edu.cn

数字化 X 射线摄影系统产生的数字辐射图像的空间分辨率往往难以满足审图人员的需求,而受到成像原理和制作工艺的限制,制造高空间分辨率的探测器将会大幅增加系统的成本和研发周期。因此在硬件系统相同的条件下,利用算法提升数字辐射图像的分辨率,恢复高分辨率图像细节具有重要意义。

图像超分辨率重建是指利用低分辨率图像或图像序列得到高分辨率图像。根据重建思路可分为 3 类: 插值算法、重建算法和基于学习的方法^[1-2]。其中利用邻域的像素点进行权重组合得到目标像素值^[3]的插值算法由于其形式简单、处理速度快的特点广泛应用于数字化 X 射线摄影系统中。然而,这类算法会损失图像高频信息,丢失图像细节,造成图像模糊,不利于审图人员作出精确的判断。文献[4-6]在这类算法的基础上提出了基于边缘的插值算法,一定程度上保留了图像的高频信息,然而基于边缘的插值算法难以处理图像的纹理区域,适用范围有着很大的限制。

不同于传统超分辨率方法,基于学习的方法利用有监督的机器学习建立低分辨率图像和高分辨率图像的非线性映射关系进行图像的重建^[7-8]。由于这类方法能从样本集中提取图像的先验信息,因此可取得更高的重建精度。然而传统的基于学习的方法只能提取图像较为简单的特征,如图像的一阶、二阶梯度等,这些特征不足以充分地表征图像信息,使图像的重建质量受到了限制。受到深度学习方法在计算机视觉领域取得的巨大成功的启发,Dong 等^[9]将深度学习应用于图像超分辨率重建问题,提出了应用卷积神经网络的单帧图像超分辨率重建算法(SRCNN),避免了人为设计特征提取方式,实现了端对端的学习,提高了图像的重建精度。然而,由于卷积神经网络中梯度弥散现象的影响, SRCNN 在卷积深度较大的情况下会出现网络退化的现象,即图像的重建质量下降,这限制了算法的重建性能。

针对 SRCNN 的上述缺陷,本文提出一种应用于超分辨率图像的卷积神经网络结构,避免网络退化现象,并对辐射图像样本进行训练,得到一种基于深度学习的辐射图像超分辨率重建方法。

1 卷积神经网络

受到猫脑皮层神经元分布的启发,Hubel 等^[10]提出了卷积神经网络这一概念。卷积神经网络可自动提取图像特征,且仅需较少的训练参数,已广泛应用于图像分类、物体检测等领域^[11]。卷积神经网络是一种由多个卷积层组成的前馈式的监督学习网络,包含输入层、隐含层和输出层,其中隐含层中的输出结果称作特征图。神经网络中各卷积层参数在初始化后,通过误差反传算法迭代优化更新。典型的卷积神经网络结构如图 1 所示。




图 1 卷积神经网络结构

Fig. 1 Architecture of convolution neural network

在卷积层中,前层中的特征图与可学习的卷积核进行卷积操作提取局部特征,卷积结果经激活函数后生成这层的特征图。1 个卷积层中有多个特征图,每个特征图提取图像的一种特征。在提取特征时,同一特征图共享一组卷积核权值,而不同特征图的卷积核权值不同,从而提取图像的不同特征。卷积核的参数在训练中不断通过误差反传算法更新,使特征提取向有利于误差减小的方向进行,卷积操作示意图如图 2 所示。一般地,卷积层的输出结果为:

$$x_j^l = f\left(\sum_{i \in M_j} x_i^{l-1} \times W_{ij}^l + b_j^l\right) \quad (1)$$

其中: x 为特征图中像素点的值; l 为卷积层的层数; j 为像素点的位置; f 为神经网络采取的激活函数; M 为卷积核; W 和 b 分别为卷积核




图 2 卷积操作示意图

Fig. 2 Scheme of convolution operation

中的权值和常数偏置。

W 和 b 在训练中不断通过误差反传算法更新。式(1)可被表示为:

$$x^l = f(u^l) \quad u^l = W^l x^{l-1} + b^l \quad (2)$$

在神经网络中,令 E 为卷积神经网络的输出误差函数,令 δ^l 为第 l 层卷积层偏置 b 引起的 E 的误差,则:

$$\delta^l = \frac{\partial E}{\partial b^l} = \frac{\partial E}{\partial u^l} \frac{\partial u^l}{\partial b^l} = \frac{\partial E}{\partial u^l} \quad (3)$$

则有如下递推关系:

$$\delta^l = \frac{\partial E}{\partial x^l} \frac{\partial x^l}{\partial u^l} = \frac{\partial E}{\partial u^{l+1}} \frac{\partial u^{l+1}}{\partial x^l} \frac{\partial x^l}{\partial u^l} = \delta^{l+1} (W^{l+1})^T f'(u^l) \quad (4)$$

$$\Delta W^l = \frac{\partial E}{\partial W^l} = \frac{\partial E}{\partial u^l} \frac{\partial u^l}{\partial W^l} = (\delta^l)^T x^{l-1} \quad (5)$$

其中 $(W^{l+1})^T$ 和 $(\delta^l)^T$ 分别为 W^{l+1} 和 δ^l 的转置,由误差反传递推关系和梯度下降算法即可在每次训练后更新各层卷积核中 W 和 b 的参数,即对式(3)和(5)中得到的 $\frac{\partial E}{\partial W^l}$ 和 $\frac{\partial E}{\partial b^l}$ 乘一个负的学习率 η 即可得到该层的权值更新:

$$\Delta W^l = \eta \frac{\partial E}{\partial W^l} = \eta \frac{\partial E}{\partial u^l} \frac{\partial u^l}{\partial W^l} = -\eta (\delta^l)^T x^{l-1} \quad (6)$$

$$\Delta b^l = \eta \frac{\partial E}{\partial b^l} = \eta \frac{\partial E}{\partial u^l} \frac{\partial u^l}{\partial b^l} = -\eta \delta^l \quad (7)$$

考虑第 l 层中 b^l 引起的 x^l 的偏差为:

$$\Delta x^l \approx \frac{\partial x^l}{\partial b^l} \Delta b^l = f'(\mu^l) \Delta b^l \quad (8)$$

第 2 层神经元的偏差 $\Delta \mu^2$ 为:

$$\Delta \mu^2 = \frac{\partial \mu^2}{\partial x^l} \Delta x^l = W^2 f'(\mu^l) \Delta b^l \quad (9)$$

类似地,最终输出误差函数的偏差 ΔE 为:

$$\Delta E = f'(x^1) W^2 f'(x^2) W^3 f'(x^3) \cdots W^n f'(x^n) \frac{\partial E}{\partial x^n} \Delta b^l \quad (10)$$

对式(10)两边同时除以 Δb^l ,则有:

$$\frac{\Delta E}{\Delta b^l} = \frac{\partial E}{\partial b^l} = f'(x^1) W^2 f'(x^2) W^3 f'(x^3) \cdots W^n f'(x^n) \frac{\partial E}{\partial x^n} \quad (11)$$

由式(11)可见,对神经网络中的激活函数 $f(x)$,若 $f'(x) < 1$,则在层数 n 较大的情况下, $\frac{\partial E}{\partial b^l} \approx 0$,即第 1 层神经网络中的参数不能得到

有效的训练,当神经网络的层数到达一定程度时会发生网络退化的现象,即更深层的神经网络的表现反而不如浅层网络,这种现象称作梯度弥散现象。

研究表明,较深层次的神经网络可提取图像更深层次的特征,具有提升图像重建性能潜力^[11]。然而由于神经网络中梯度弥散现象,更深层的神经网络的表现往往不如浅层网络。文献[9]亦出现了类似现象,采用多层结构的 SRCNN 在样本训练中出现了网络退化的现象,重建质量反而不如 3 层的神经网络。文献[12]中提出了残差网络结构的概念,残差结构(图 3)在深层网络中利用跨层将浅层和深层的卷积层连接,使卷积层对特征图的残差进行拟合,大幅降低了训练过程的计算复杂度。本文发现采用这种结构的深层神经网络大幅地提升了模型的训练速度和精度,在图像识别和物体检测等领域均取得了很好的效果。深层残差网络结构的提出使真正意义上的深层网络成为可能。




图 3 残差结构

Fig. 3 Residual block

2 本文方法

本文将残差网络结构引入超分辨率重建任务,提出了基于深度学习的超分辨率重建(SRDL)方法,该方法重建的图像主要由两部分组成,即:

$$\hat{Y}(X) = B(X) + C(X) \quad (12)$$

其中: \hat{Y} 为重建图像; X 为原始低分辨率辐射图像; $B(X)$ 为由低分辨率图像直接进行双三次插值得到的图像,为图像的低频部分; $C(X)$ 为低分辨率图像经过一系列级联的卷积层后的输出图像,为图像的高频部分。这样的结构有利于避免神经网络对图像低频信息的重复学习,

加快模型的收敛速度。

SRDL 方法中的卷积神经网络部分由 18 层具有残差结构的级联卷积层组成,这一深度大幅超越了 SRCNN^[9]。其中,卷积层的输出为与低分辨率图像尺寸相同的特征图,每层的卷积核尺寸为 3×3 ,数量为 16 个。这样的参数设置不但能有效降低模型参数,而且可更好地处理图像细节,从而得到更好的重建效果。图 4 为本文算法网络结构。




图 4 本文算法网络结构

Fig. 4 Structure of proposed network

卷积层后采用线性修正单元(ReLU)作为激活单元,即图像经过每 l 个卷积层的输出特征图 C_l 为:

$$C_l = \max(0, W_l C_{l-1} + b_l) \quad (13)$$

其中, W_l 和 b_l 分别为第 l 层卷积核的权值和偏置。

3 实验分析

由于超分辨率重建的任务是得到与原始高分辨率图像尽可能相近的重建图像,因此对于数据集 $\{X_i, Y_i\}_{i=1}^N$,训练的目标为求解使原始高分辨率图像 Y 和重建图像 \hat{Y} 的平均欧氏距离最小的卷积网络参数 W 和 b ,即:

$$W, b = \arg \min_{W, b} \frac{1}{2N} \|Y_i - \hat{Y}_i\|_2^2 \quad (14)$$

另外,本文将峰值信噪比 PSNR 作为衡量图像重建质量的指标,对于高分辨率图像 Y 和重建图像 \hat{Y} ,PSNR 为:

$$\text{PSNR}(Y, \hat{Y}) = 10 \lg \frac{255^2}{\frac{1}{N_1 N_2} \sum_{k=1}^{N_1} \sum_{l=1}^{N_2} (x_{kl} - \hat{x}_{kl})^2} \quad (15)$$

3.1 模型训练

本文训练过程中采用的优化算法为随机梯度下降法,并采用可变学习率的策略。初始学习率 η 为 0.1,每完成 10 次对训练集中全样本

的训练,学习率下降为之前的 10%,此策略可保证模型迅速收敛的同时抑制梯度弥散现象,使模型收敛在一较优的位置。

本文采取 50 张辐射图像组成的训练集,对放大倍数为 n 的模型,将训练集中的图像随机切割为尺寸为 $(n \times 37) \times (n \times 37)$ 的图像区块,作为高分辨率图像的训练样本,并将其缩小为 37×37 的图像区块作为相应的低分辨率图像的训练样本。作为参照,本文还利用 SRCNN 对训练集中的样本进行训练,训练代码为文献 [9] 中的源代码。上述训练过程均采用 caffe 工具包完成,训练平台采用 CPU 为 intel i7 6800K, GPU 为 nvidia gtx 1080,内存为 32 GB 的台式工作站。

图 5 为在不同迭代次数下,两种方法对测试集中辐射图像的重建信噪比曲线。可看出,SRDL 方法的信噪比上升速度快于 SRCNN,且重建精度优于 SRCNN。由于 SRDL 方法采用的初始学习率较高,其信噪比曲线较为震荡,使用较小的学习率可改善这一现象。

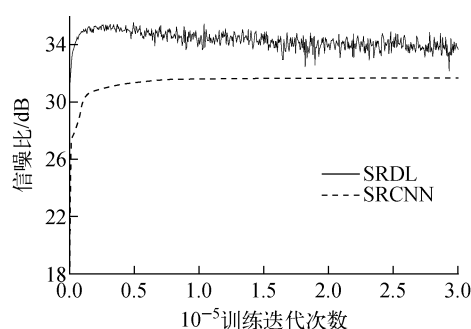


图 5 两种方法信噪比收敛曲线

Fig. 5 Convergence curves of two methods

3.2 与其他方法比较

基于以上分析,利用已训练的 SRDL 模型对测试集中的辐射图像进行处理,并对其运行时间和重建图像信噪比与其他方法进行比较,程序均用 Matlab 2015b 编写,硬件平台为采用 intel i7 6800K 处理器,内存为 32 GB 的台式工作站。表 1 为不同方法对尺寸为 1024×1024 的辐射图像在不同放大倍数下的处理结果,其中双三次插值处理时间可忽略不计。可看出,针对不同辐射图像,SRDL 方法表现均较好,且放大倍数越大时优势越明显。图 6

为不同方法在放大倍数为 4 的重建辐射图像
的指标分析和视觉比较。可看出 ,SRDL 重建
图像边缘更加清晰 ,细节更加丰富 ,视觉效果
较好 ,图像信噪比显著优于双三次插值方法
和 SRCNN ,运行速度亦快于 SRCNN ,可满足
实时需求。

表 1 不同方法重建辐射图像的信噪比和时间
Table 1 PSNR and time of radiation image reconstruction with different methods

测试图像	放大倍数	信噪比 /dB			时间 /s		
		双三次插值	SRCNN	SRDL	双三次插值	SRCNN	SRDL
LR1	×2	32.79	34.04	36.52	—	11.09	3.36
	×3	29.83	30.68	32.30	—	10.84	3.58
	×4	27.92	28.46	29.69	—	11.17	3.85
LR2	×2	33.17	34.55	36.36	—	11.43	3.51
	×3	30.13	31.07	32.39	—	11.16	3.62
	×4	28.29	29.23	30.05	—	10.98	3.97
LR3	×2	32.89	34.24	36.19	—	11.43	3.39
	×3	30.07	30.96	32.27	—	11.16	3.71
	×4	28.16	29.09	29.92	—	10.98	3.57




图 6 放大倍数为 4 的重建后辐射图像

Fig. 6 Super-resolution reconstruction radiation image with scale factor of 4

4 结论

本文将残差网络结构引入超分辨率任务 ,
提出了基于深度学习的辐射图像超分辨率重建
方法。该方法将残差结构引入卷积神经网络 ,
对训练集中的辐射图像样本进行拟合 ,得到了
低分辨率辐射图像和高分辨率辐射图像的映射
关系。对本文方法与其他几种常见的重建方法
进行了比较 ,分析了不同方法的信噪比、运行
时间和重建图像的视觉效果。实验证明 ,本文
方法重建的图像在量化指标和主观视觉效果上
均优于其他几种重建方法 ,同时具备较快的
处理速度 ,且有较强的实用价值。

参考文献:

[1] BAKER S , KANADE T. Limits on super-resolution and how to break them [J]. IEEE Transactions on Pattern Analysis & Machine Intelligence , 2000 , 24 (9) : 1 167-1 183.

[2] 苏衡 ,周杰 ,张志浩. 超分辨率图像重建方法综述 [J]. 自动化学报 2013 , 39(8) : 1 202-1 213. SU Heng , ZHOU Jie , ZHANG Zhihao. Survey of super-resolution image reconstruction methods [J]. Acta Automatica Sinica , 2013 , 39(8) : 1 202-1 213(in Chinese) .

[3] KEYS R. Cubic convolution interpolation for digital image processing [J]. IEEE Transactions on Acoustics Speech & Signal Processing , 1981 , 29(6) : 1 153-1 160.

- [4] ALLEBACH J , WONG P W. Edge-directed interpolation [C] // International Conference on Image Processing. [S. l.]: [s. n.], 1996.
- [5] LI X , ORCHARD M T. New edge-directed interpolation [J]. IEEE Transactions on Image Processing , 2000 , 10(10) : 1 521-1 527.
- [6] 杜月林 , 韩小萱. 基于边缘检测的图像超分辨率重建研究 [J]. 国外电子测量技术 , 2012 , 31(10) : 22-26.
DU Yuelin , HAN Xiaoxuan. The research of super-resolution image reconstruction based on edge detection [J]. Foreign Electronic Measurement Technology , 2012 , 31(10) : 22-26(in Chinese) .
- [7] YANG J , WRIGHT J , HUANG T S , et al. Image super-resolution via sparse representation [J]. IEEE Transactions on Image Processing , 2010 , 19(11) : 2 861-2 873.
- [8] TIMOFTE R , DE V , GOOL L V. Anchored neighborhood regression for fast example-based super-resolution [C] // IEEE International Conference on Computer Vision. Sydney: IEEE Computer Society , 2013: 1 920-1 927.
- [9] DONG C , CHEN C L , HE K , et al. Image super-resolution using deep convolutional networks [J]. IEEE Transactions on Pattern Analysis & Machine Intelligence , 2016 , 38(2) : 295-307.
- [10] HUBEL D H , WIESEL T N. Receptive fields , binocular interaction and functional architecture in the cat' s visual cortex [J]. Journal of Physiology , 1959 , 148: 574-591.
- [11] HE K , ZHANG X , REN S , et al. Spatial pyramid pooling in deep convolutional networks for visual recognition [J]. IEEE Transactions on Pattern Analysis & Machine Intelligence , 2014 , 37(9) : 1 904-1 916.
- [12] HE K , ZHANG X , REN S , et al. Deep residual learning for image recognition [C] // IEEE Conference on Computer Vision and Pattern Recognition. Zurich: IEEE Computer Society , 2016: 770-778.